



UNIVERSIDAD NACIONAL DE SAN JUAN

FACULTAD DE CIENCIAS EXACTAS FÍSICAS Y NATURALES DEPARTAMENTO DE
INFORMÁTICA

Asignatura: Teoría de Información

TRABAJO PRÁCTICO: ÁREA TEMÁTICA N° 1

Alumnos:

- Baltasar Ortiz, 21752
- Gonzalo Balderrama, E-010-7
- Martin Coto, E010-114
- Octavio Garelo, 21438

PRÁCTICO 1: TEORÍA DE LA INFORMACIÓN

1. Análisis de Capacidad e Información en Imágenes Digitales

a) Suponga una imagen de alta definición (HD) dividida en una matriz de 1920 por 1080 píxeles. Indique la cantidad máxima teórica de información (en bits y en Megabytes) que proporciona este cuadro si está codificada en 24 bits por píxel.

b) Luego, considere una imagen en resolución 4K (3840 x 2160 píxeles). ¿Cuánta información máxima se genera si se codifica en formato HDR (High Dynamic Range) utilizando 10 bits por cada canal de color (Rojo, Verde y Azul)?

c) **Análisis teórico:** La cantidad de información calculada en los incisos anteriores, ¿representa la información "real" (Entropía) de una fotografía o únicamente su capacidad máxima de almacenamiento? Justifique su respuesta explicando el concepto de redundancia espacial.

Resolución

a) Imagen HD (1920 × 1080, 24 bits/píxel)

Cantidad de píxeles: $N = 1920 \times 1080 = 2.073.600$ píxeles

Cantidad máxima de información: $I_{\max} = N \times 24 = 2.073.600 \times 24 = 49.766.400$ bits

En bytes: $49.766.400 / 8 = 6.220.800$ bytes

En Megabytes (usando la convención binaria $1 \text{ MB} = 2^{20} \text{ bytes} = 1.048.576 \text{ bytes}$): $6.220.800 / 1.048.576 \approx$
5,93 MB

b) Imagen 4K HDR (3840 × 2160, 10 bits por canal, 3 canales RGB)

Cantidad de píxeles: $N = 3840 \times 2160 = 8.294.400$ píxeles

Bits por píxel: $10 \times 3 \text{ canales} = 30$ bits/píxel

Cantidad máxima de información: $I_{\max} = 8.294.400 \times 30 = 248.832.000$ bits

En bytes: $248.832.000 / 8 = 31.104.000$ bytes

En Megabytes ($1 \text{ MB} = 1.048.576 \text{ bytes}$): $31.104.000 / 1.048.576 \approx$ **29,66 MB**

c) **Análisis teórico:**

Los valores calculados en a) y b) **no representan la entropía real** de la fotografía; representan únicamente su **capacidad máxima teórica de almacenamiento**.

Según la teoría de Shannon, la entropía de una fuente cumple: $0 \leq H(A) \leq \log_2(n)$

El límite superior $\log_2(n)$ (en este caso, $\log_2(2^{24}) = 24$ bits/símbolo o $\log_2(2^{30}) = 30$ bits/símbolo) sólo se alcanza cuando **todos los símbolos son equiprobables y estadísticamente independientes**. Al calcular "24 bits

por píxel" o "30 bits por píxel" simplemente se está multiplicando la cantidad de píxeles por el ancho de codificación de cada uno. Es decir, se calcula la **capacidad del "contenedor"**, no la información que efectivamente aporta la imagen.

Una fotografía real está lejos de cumplir esas condiciones porque presenta **redundancia espacial**: los píxeles vecinos tienden a tener valores de color muy similares (el cielo es azul en una región extensa, una pared es de un color uniforme, etc.). Esto significa que:

- Conociendo el valor de un píxel, el valor del píxel adyacente es altamente predecible (no es independiente).
- Los valores de intensidad no se distribuyen de forma uniforme (no son equiprobables); ciertos tonos son mucho más frecuentes que otros.

Como consecuencia, la entropía real $H(A)$ de la imagen es **mucho menor** que la capacidad máxima $\log_2(n)$. La diferencia entre ambas es justamente la **redundancia** de la fuente: $R = 1 - H(A) / H_{\max}$

Esta redundancia espacial es la que aprovechan los algoritmos de compresión (JPEG, PNG, etc.) para reducir drásticamente el tamaño del archivo sin necesidad de almacenar la capacidad máxima teórica calculada en los incisos a) y b).

2. Cantidad de Información en Modelos de Predicción de Texto

Un sistema de autocompletado en un dispositivo móvil debe predecir la siguiente palabra que escribirá un usuario.

a) Si el vocabulario total del diccionario del sistema es de 15.000 palabras y, al iniciar una frase, el sistema asume *a priori* que cualquier palabra es equiprobable, ¿cuánta información (en bits) se genera al elegir una palabra exacta?

b) Suponga que, analizando el contexto de las palabras anteriores, un modelo de Inteligencia Artificial determina que sólo hay 5 palabras lógicas posibles para continuar la frase, siendo estas 5 opciones equiprobables. ¿Cuánta información se genera ahora al confirmar cuál de esas 5 es la palabra correcta?

c) ¿Qué cantidad de información (en bits) aportó el contexto procesado por la Inteligencia Artificial al sistema? Explique qué significa este valor en términos de incertidumbre.

Resolución

Usamos la fórmula de cantidad de información para un suceso equiprobable dentro de un conjunto de n alternativas: $I = \log_2(1/P) = \log_2(n)$

a) Sin contexto (15.000 palabras equiprobables) $I_a = \log_2(1/1/15000) = \log_2(15.000) \approx 13,87$ bits

b) Con contexto de la IA (5 palabras equiprobables) $I_b = \log_2(5) \approx 2,32$ bits

c) Información aportada por el contexto

La cantidad de información que aportó el contexto es la **diferencia** entre la incertidumbre inicial y la incertidumbre final: $\Delta I = I_a - I_b = 13,87 - 2,32 \approx 11,55$ bits

Este valor representa cuánta incertidumbre fue eliminada por el modelo de IA al analizar el contexto. Antes de procesar el contexto, el sistema tenía una incertidumbre equivalente a elegir entre 15.000 alternativas;

después de procesarlo, la incertidumbre se redujo a elegir entre solo 5. Los 11,55 bits "ganados" son información pura en el sentido de Shannon: el contexto no cambió la palabra elegida en sí, pero redujo drásticamente el espacio de búsqueda, que es exactamente lo que la Teoría de la Información define como "recibir información", la disminución del rango de incertidumbre del receptor.

3. Propiedades Matemáticas de la Información

a) Demostrar las siguientes igualdades correspondientes a la propiedad de cambio de base de los logaritmos:

$$\log_a(x) = \log_b(x) / \log_b(a) = \log_a(b) \times \log_b(x)$$

b) **Justificación Teórica:** Indique en qué situaciones prácticas de la Teoría de la Información resulta indispensable utilizar esta propiedad de cambio de base (Pista: Relacione este concepto con las unidades de medida de la información).

Resolución

a) Demostración

Sea $y = \log_a x$, por definición: $a^y = x$.

Aplicando $\log_b$, a ambos lados:

$$\log_b(a^y) = \log_b x \Rightarrow y \cdot \log_b a = \log_b x \Rightarrow y = \frac{\log_b x}{\log_b a}$$

con lo cual queda demostrado que:

$$\log_a x = \frac{\log_b x}{\log_b a}$$

Para la segunda igualdad, aplicamos la fórmula anterior con $x = b$:

$$\log_a b = \frac{\log_b b}{\log_b a} = \frac{1}{\log_b a}$$

Reemplazando en la primer expresión:

$$\log_a x = \frac{\log_b x}{\log_b a} = \log_b x \cdot \frac{1}{\log_b a} = \log_b x \cdot \log_a b$$

b) Justificación teórica:

Esta propiedad es indispensable en Teoría de la Información porque la **unidad de medida de la información depende directamente de la base del logaritmo utilizada:**

- Base 2 → **bit** (utilizada en la fórmula de Shannon $H(A) = -\sum p_i \times \log_2(p_i)$)
- Base e (logaritmo natural) → **nat**
- Base 10 → **Hartley** (o dit)

En la práctica, esto es indispensable en situaciones como:

1. **Conversión entre unidades de información:** si un cálculo se realizó en nats (por ejemplo, porque una librería de software como NumPy usa logaritmo natural por defecto) y se necesita expresar el resultado en bits, se debe aplicar el cambio de base: $H_{\text{bits}} = H_{\text{nats}} / \ln(2)$.
2. **Entropía en unidades r-arias:** cuando se trabaja con alfabetos de base distinta de 2 (por ejemplo, sistemas ternarios como trits), la entropía medida en esas unidades se calcula como $H_r(S) = H(S) / \log(r)$, que es una aplicación directa del cambio de base.
3. **Comparación de sistemas con distinta base de codificación:** por ejemplo, al comparar la eficiencia de un sistema binario contra uno ternario, es necesario expresar ambas entropías/capacidades en una base común para poder compararlas de manera justa.

Para resumir, el cambio de base permite "traducir" cantidades de información entre distintos sistemas de unidades sin alterar el contenido informativo real que representan.

4. Entropía en Sistemas de Reconocimiento Automático

En el desarrollo de un modelo de Machine Learning para la traducción automatizada, el sistema debe clasificar 5 configuraciones básicas (c_1, c_2, c_3, c_4, c_5). Tras analizar un corpus de datos, se determina que la configuración c_1 es la más frecuente, con una probabilidad $p_1 = 1/3$, mientras que las otras cuatro configuraciones son equiprobables con $p = 1/6$ cada una.

- a) Calcula la cantidad de información individual que aporta la detección de cada configuración.
- b) Calcula la entropía total de esta fuente de información.
- c) Si el sistema se calibra para que todas las configuraciones tengan exactamente la misma probabilidad de aparición, ¿la entropía aumentaría o disminuiría? Justifica tu respuesta.

Resolución

Verificamos que las probabilidades suman 1: $1/3 + 4 \times (1/6) = 2/6 + 4/6 = 1$

a) Información individual

$$I(c_1) = \log_2(1 / (1/3)) = \log_2(3) \approx \mathbf{1,585 \text{ bits}}$$

$$I(c_2) = I(c_3) = I(c_4) = I(c_5) = \log_2(1 / (1/6)) = \log_2(6) \approx \mathbf{2,585 \text{ bits}}$$

b) Entropía total

Aplicando la fórmula de Shannon

$$H(A) = \sum_{i=1}^n p_i * I_i = - \sum_{i=1}^n p_i * \log_2(p_i)$$

$$H(A) = (1/3) \times \log_2(3) + 4 \times (1/6) \times \log_2(6)$$

$$H(A) = (1/3) \times (1,585) + (2/3) \times (2,585)$$

$$H(A) \approx 0,5283 + 1,7233 \approx \mathbf{2,2516 \text{ bits/símbolo}}$$

c) ¿Aumenta o disminuye si se calibra la equiprobabilidad?

Si las 5 configuraciones fueran equiprobables ($p = 1/5$ cada una), la entropía sería:

$$H_{\max} = \log_2(5) \approx 2,3219 \text{ bits}$$

Como $2,3219 > 2,2516$, **la entropía aumentaría.**

Esto se justifica directamente por la propiedad fundamental de la entropía: $0 \leq H(A) \leq \log_2(n)$

donde la cota superior $\log_2(n)$ se alcanza **única y exclusivamente** cuando todos los símbolos son equiprobables. La distribución actual (c_1 más frecuente que el resto) ya introduce cierta previsibilidad en el sistema (sabemos que es más probable que aparezca c_1), lo cual reduce la incertidumbre promedio por debajo del máximo teórico. Al forzar la equiprobabilidad se maximiza la incertidumbre del sistema, y por lo tanto la entropía alcanza su valor más alto posible para 5 símbolos.

5. Entropía Máxima vs. Entropía Real en un Pipeline de Datos

Un *pipeline* de backend clasifica las peticiones entrantes de los usuarios en 8 categorías o intenciones distintas.

a) Demuestra matemáticamente que si el balanceador de carga distribuye las peticiones de forma tal que las 8 categorías tienen exactamente la misma probabilidad de ocurrir, el sistema alcanza su máxima incertidumbre (entropía máxima). ¿Cuál es ese valor en bits?

b) Al pasar el sistema a producción, se observa que el tráfico real está fuertemente sesgado, respondiendo a la siguiente distribución de probabilidades: $p_1=0,5$, $p_2=0,2$, $p_3=0,1$, $p_4=0,08$, $p_5=0,06$, $p_6=0,04$, $p_7=0,015$, $p_8=0,005$. Calcula la entropía real del sistema en producción.

c) Compara ambos resultados (inciso a vs inciso b). ¿Qué nos dice esta diferencia (caída de entropía) sobre la predictibilidad del comportamiento de los usuarios?

Resolución

a) Entropía máxima (8 categorías equiprobables)

Con $n = 8$ categorías equiprobables, $p_i = 1/8$ para todo i .

Aplicando la fórmula de Shannon:

$$\begin{aligned} H_{\max} &= -\sum (1/8) \times \log_2(1/8) \\ &= -8 \times (1/8) \times \log_2(1/8) \\ &= -\log_2(1/8) \\ &= \log_2(8) \end{aligned}$$

$$H_{\max} = \log_2(8) = 3 \text{ bits/símbolo}$$

Esto coincide exactamente con la propiedad $H_{\max} = \log_2(n)$ demostrada en la teoría: cuando la distribución es uniforme, la sumatoria de Shannon se reduce algebraicamente a $\log_2(n)$, que es matemáticamente el valor máximo que puede alcanzar $H(A)$ para un alfabeto de n símbolos.

b) Entropía real en producción

Verificamos que las probabilidades suman 1: $0,5+0,2+0,1+0,08+0,06+0,04+0,015+0,005 = 1,00$

$$H_{\text{real}} = -\sum p_i \times \log_2(p_i)$$

Calculando cada término:

p_i	$-p_i \times \log_2(p_i)$
0,5	0,5000
0,2	0,4644
0,1	0,3322
0,08	0,2915
0,06	0,2435
0,04	0,1858
0,015	0,0909
0,005	0,0382

$$H_{\text{real}} \approx 2,1465 \text{ bits/símbolo}$$

c) Comparación e interpretación

$$H_{\text{max}} - H_{\text{real}} = 3 - 2,1465 \approx 0,8535 \text{ bits}$$

Esta caída de entropía (equivalente a una redundancia $R = 1 - H_{\text{real}}/H_{\text{max}} \approx 28,5\%$) indica que el comportamiento real de los usuarios **es bastante más predecible** que en el escenario ideal de máxima incertidumbre. En producción, más de la mitad del tráfico ($p_i=0,5$) corresponde a una sola categoría, mientras

que las últimas categorías son casi anecdóticas (p_7 , p_8). Esto significa que, en promedio, conocer de antemano "qué categoría es más probable" ya reduce bastante la sorpresa del sistema al recibir cada petición.

6. Entropía Teórica vs. Redundancia en el Lenguaje

Considere un alfabeto teórico de 27 letras.

a) Calcule la cantidad de información (Entropía Máxima) que genera la elección de 1 sola letra, una secuencia de 2 letras y una secuencia de 3 letras, asumiendo *a priori* que todas las letras son equiprobables y la elección de cada letra es completamente independiente de las demás.

b) Si pasamos de este "alfabeto teórico" al uso real del **idioma español**, el principio de equiprobabilidad desaparece. Explique por qué sucede esto y cómo afecta al valor de la entropía real de un carácter.

c) En el idioma español tampoco se cumple el principio de independencia (las letras están condicionadas por las anteriores). Dé un ejemplo de dependencia fuerte entre dos letras en español y explique conceptualmente qué sucede con la cantidad de información generada al leer la segunda letra.

Resolución

a) Entropía máxima teórica (27 letras equiprobables e independientes)

Para 1 letra: $H_1 = \log_2(27) \approx \mathbf{4,7549 \text{ bits}}$

Como las letras son independientes, la entropía de una secuencia de n símbolos es n veces la entropía de un símbolo (extensión de orden n : $H(A^n) = n \times H(A)$):

Para 2 letras: $H_2 = 2 \times H_1 = 2 \times 4,7549 \approx \mathbf{9,5098 \text{ bits}}$

Para 3 letras: $H_3 = 3 \times H_1 = 3 \times 4,7549 \approx \mathbf{14,2647 \text{ bits}}$

b) En el "alfabeto teórico" se asume que todas las letras tienen la misma probabilidad de aparecer ($1/27$), pero esto **no ocurre en el idioma real**: en español, letras como *e*, *a*, *o*, *s* aparecen con muchísima más frecuencia que letras como *w*, *k* o *x*. La distribución de frecuencias del español está fuertemente sesgada.

Por la propiedad fundamental $H(A) \leq \log_2(n)$ (con igualdad solo en el caso equiprobable), esta pérdida de equiprobabilidad hace que la **entropía real de un carácter en español sea considerablemente menor** que el máximo teórico de 4,75 bits. En la práctica, la entropía de primer orden (sin considerar dependencias) de un carácter en español ronda aproximadamente los 4 bits, y baja aún más cuando se incorpora el efecto de las dependencias entre letras.

c) Un ejemplo clásico de dependencia fuerte en español es la secuencia **"q" seguida de "u"**: prácticamente el 100% de las veces que aparece la letra "q", la letra siguiente es "u" (como en "que", "quien", "quiso"). Es decir: $P(u | q) \approx 1$

Conceptualmente, esto significa que la cantidad de información que aporta leer la segunda letra, **una vez que ya se conoce la primera**, es casi nula: $I(u | q) = \log_2(1 / P(u|q)) = \log_2(1/1) \approx \mathbf{0 \text{ bits}}$

En otras palabras, al leer una "q" el lector (o el sistema) ya "sabe" casi con certeza que la próxima letra será "u", por lo que la aparición efectiva de la "u" no reduce ninguna incertidumbre adicional — no aporta información nueva porque ya era predecible. Esto es consistente con el concepto de **entropía condicional** de

una fuente de Markov ($H(S|s_{\square})$), la cual siempre es menor o igual a la entropía sin condicionar: $H(S_{\text{markov}}) \leq H(S)$. Este tipo de dependencias es justamente lo que permite comprimir texto en lenguaje natural mucho más allá de lo que permitiría un modelo que solo considere las frecuencias individuales de las letras.

7.Computación Ternaria y Economía de la Base (Radix Economy)

En 1958, la Universidad Estatal de Moscú construyó la computadora "Setun", la cual no utilizaba lógica binaria (bits, base 2), sino lógica ternaria (trits, base 3). Los ingenieros se basaron en el teorema de la "Economía de la Base", el cual postula que el costo de hardware C de un registro es proporcional a la cantidad de dígitos necesarios (I) multiplicada por los niveles de voltaje que debe distinguir cada dígito (la base b). Es decir, $C=I \times b$.

Para un sistema que debe poder representar $V = 1.000.000$ de estados diferentes:

- Calcule cuántos "bits" ($b=2$) y cuántos "trits" ($b=3$) enteros se necesitan como mínimo. Aplique la fórmula de costo para ambos y demuestre aritméticamente cuál arquitectura es más económica.
- Más allá de comparar base 2 y base 3, demuestre analíticamente (utilizando la primera derivada) cuál es la base teórica (número real absoluto) que minimiza la función de costo C para cualquier valor de V .
- Si la base 3 es matemáticamente superior, investigue o deduzca por qué la industria global abandonó proyectos como la "Setun" y adoptó el estándar binario.

Resolución

a) Cantidad de dígitos necesarios y costo

La cantidad mínima de dígitos enteros necesarios en base b para representar V estados distintos es:

$$I = \log_b(V)$$

$$\text{En binario (b=2): } \log_2(1.000.000) \approx 19,9316 \rightarrow I_{\text{bits}} = 19,9316 =_{\text{redondeando}} \mathbf{20 \text{ bits}}$$

$$\text{En ternario (b=3): } \log_3(1.000.000) \approx 12,5754 \rightarrow I_{\text{trits}} = 12,5754 =_{\text{redondeando}} \mathbf{13 \text{ trits}}$$

Aplicando la fórmula de costo $C = I \times b$:

$$C_{\text{bits}} = 20 \times 2 = \mathbf{40}$$

$$C_{\text{trits}} = 13 \times 3 = \mathbf{39}$$

Como $39 < 40$, el sistema **ternario resulta más económico** que el binario para representar 1.000.000 de estados, ya que requiere menos "costo de hardware" total según el modelo propuesto.

b) Base teórica óptima (demostración analítica)

Partiendo de $C(b) = I \cdot b$ con $I = \frac{\ln V}{\ln b}$:

$$C(b) = \frac{b \cdot \ln V}{\ln b}$$

Derivando respecto de b (con $\ln V$ constante):

$$\frac{dC}{db} = \ln V \cdot \frac{\ln b - b \cdot \frac{1}{b}}{(\ln b)^2} = \ln V \cdot \frac{\ln b - 1}{(\ln b)^2}$$

Igualando a cero: $\ln b - 1 = 0 \Rightarrow \ln b = 1 \Rightarrow b = e \approx 2,71828$

$$b_{\text{óptimo}} = e \approx 2,71828$$

Analizando el signo de la derivada a ambos lados de $b=e$ se confirma que es un **mínimo**: para $b < e$ la derivada es negativa (el costo decrece al aumentar b) y para $b > e$ es positiva (el costo vuelve a crecer). Por lo tanto, la base real que minimiza matemáticamente el costo de un sistema numérico es el número de Euler $e \approx 2,718$.

Este resultado explica por qué, entre las bases enteras, la **base 3 es la más eficiente**: es la base entera más cercana al valor óptimo teórico $e \approx 2,718$ (más cercana que 2 y mucho más cercana que 4), lo cual es consistente con el resultado numérico del inciso a).

c) ¿Por qué la industria adoptó binario en lugar de ternario?

Aunque matemáticamente la base 3 (y en el límite continuo, e) minimiza el costo teórico $C=I \times b$, la industria global abandonó proyectos como la Setun y adoptó el estándar binario por razones de **ingeniería práctica** que el modelo teórico no contempla:

- **Simplicidad y fiabilidad de los circuitos**: un sistema binario solo necesita distinguir dos estados físicos (hay tensión / no hay tensión, encendido/apagado), lo cual es extremadamente simple y robusto de implementar electrónicamente. Un sistema ternario requiere distinguir tres niveles discretos de voltaje, lo cual exige mayor precisión analógica y es mucho más sensible al ruido eléctrico, aumentando la tasa de errores.
- **Base matemática y teórica ya desarrollada**: el álgebra booleana, las puertas lógicas (AND, OR, NOT) y toda la teoría de conmutación (switching theory) fueron desarrolladas específicamente para lógica de dos estados, brindando una base sólida, simple y ya probada para el diseño de circuitos digitales.
- **Economías de escala**: una vez que la industria se estandarizó en binario, toda la inversión en fabricación de semiconductores, herramientas de diseño (EDA), lenguajes de programación y software se construyó sobre esa base, haciendo que un cambio de paradigma fuera económicamente inviable a pesar del beneficio teórico marginal.

- **Beneficio marginal pequeño:** la ganancia de pasar de base 2 a base 3 es relativamente chica (39 vs. 40 en el ejemplo, es decir apenas un 2,5% de mejora), mientras que el costo de ingeniería y el riesgo de errores por ruido en un sistema de 3 niveles son considerablemente mayores.

8. Árboles de Decisión y Capacidad de Información

Se tienen 12 monedas de apariencia idéntica, pero se sabe que exactamente una de ellas es falsa y tiene un peso diferente al resto (no se sabe *a priori* si es más pesada o más liviana). Usted dispone de una balanza de platillos clásica.

a) Sabiendo que cada pesada en la balanza (equilibrio, se inclina a la izquierda, se inclina a la derecha) genera una cierta cantidad de información, demuestre matemáticamente por qué son necesarias exactamente 3 pesadas para encontrar la moneda falsa y determinar su anomalía de peso.

b) Esquematice la metodología (el árbol de decisiones) de la primera pesada y de todas sus ramas para demostrar cómo se divide el espacio de incertidumbre respetando la base ternaria calculada.

Resolución

a) Demostración de que se necesitan exactamente 3 pesadas

Cada pesada en una balanza de platillos tiene **3 resultados posibles** (equilibrio, inclinación a la izquierda, inclinación a la derecha), por lo que cada pesada aporta como máximo: $I_{\text{pesada}} = \log_2(3) \approx 1,585$ bits

Por otro lado, el número total de "estados" posibles a distinguir es: cuál de las 12 monedas es la falsa **y** si es más pesada o más liviana, es decir: $N_{\text{estados}} = 12 \times 2 = 24$ posibilidades

La incertidumbre inicial del sistema es entonces: $I_{\text{necesaria}} = \log_2(24) \approx 4,585$ bits

Para poder distinguir las 24 posibilidades, la cantidad de información total generada por las n pesadas debe ser al menos igual a la incertidumbre inicial: $n \times \log_2(3) \geq \log_2(24)$

Despejando n : $n \geq \log_2(24) / \log_2(3) \approx 4,585 / 1,585 \approx 2,89$

Como n debe ser un número entero, $n=3$ es el mínimo que satisface la desigualdad. Esto también puede verificarse directamente comparando la cantidad de resultados distinguibles con n pesadas (3^n) contra las 24 posibilidades a distinguir:


$3^2 = 9 < 24$ (2 pesadas NO alcanzan)

$3^3 = 27 \geq 24$ (3 pesadas SÍ alcanzan)

Por lo tanto, quedan demostradas matemáticamente las **3 pesadas mínimas necesarias**, siendo esta la aplicación directa de que cada pesada, al tener 3 resultados posibles, genera información en base ternaria.

b) Esquema de la primera pesada (árbol de decisión)

Primera pesada: A(4) vs B(4) | C(4) queda aparte
(Total: 12 monedas, 24 posibilidades)



Como se observa, **cada una de las 3 ramas deja exactamente 8 posibilidades restantes** ($24/3=8$), respetando perfectamente la base ternaria: la incertidumbre se reparte de manera equilibrada entre los tres resultados posibles de la pesada, maximizando la información obtenida en cada paso ($\log_2(3)$ bits exactos por pesada). A partir de cada una de estas 3 ramas (8 posibilidades cada una), se repite el mismo criterio de división en tres (aproximadamente $8/3 \approx 2-3$ monedas involucradas por sub-pesada) hasta llegar, en la tercera pesada, a una única posibilidad que identifica con certeza la moneda falsa y si es más pesada o más liviana.

9. Información y Reducción de Incertidumbre

En un programa de preguntas, el candidato debe encontrar un premio oculto detrás de una de tres puertas. El premio está detrás de cada puerta con igual probabilidad; una cabra está detrás de las otras dos puertas. Primero, el candidato elige una puerta.

a) ¿Cuál es la probabilidad de que el premio esté detrás de la puerta elegida?

b) El presentador del juego sabe detrás de qué puerta está oculto el premio. En lugar de abrir la puerta elegida, abre una de las otras dos puertas que contiene una cabra. Ahora, ofrece al candidato cambiar a la única puerta cerrada que queda. ¿Cuál es la probabilidad de ganar el premio cambiando de puerta?

c) **Análisis de la Información:** En términos de la Teoría de la Información, el estado inicial del juego posee una incertidumbre máxima. Cuando el presentador abre una puerta con una cabra, está transmitiendo un "mensaje" al candidato. Calcule la Entropía inicial del sistema y explique conceptualmente por qué la acción del presentador inyecta Información al sistema, rompiendo la equiprobabilidad.

Resolución

a) Probabilidad inicial

Al elegir una puerta entre 3 opciones equiprobables, la probabilidad de que el premio esté detrás de la puerta elegida es: $P(\text{premio en puerta elegida}) = 1/3$

b) Probabilidad de ganar cambiando de puerta

$P(\text{ganar cambiando}) = 2/3$

Ya que el presentador abrió una de las puertas mostrando una cabra las posibilidades de ganar aumentan.

c) Análisis de la información: entropía inicial e inyección de información

Entropía inicial: al comienzo del juego hay 3 puertas equiprobables, por lo que la incertidumbre máxima del sistema es: $H_{\text{inicial}} = \log_2(3) \approx 1,585 \text{ bits}$

¿Por qué la acción del presentador inyecta información?

La clave conceptual es que la acción del presentador **no es aleatoria**: él conoce con certeza dónde está el premio y, por reglas del juego, jamás abre la puerta con el premio ni la puerta que el candidato ya eligió. Esto significa que su elección de qué puerta abrir está **condicionada** por información que el candidato no tiene, y al abrir la puerta el presentador le transmite parte de esa información al candidato, rompiendo la simetría original entre las tres puertas.

Podemos cuantificar exactamente cuánta información se transmite comparando la entropía antes y después del mensaje del presentador. Después de abrir la puerta con la cabra, la incertidumbre del candidato ya no está repartida equiprobablemente entre las dos puertas restantes: la puerta originalmente elegida sigue teniendo probabilidad $1/3$, mientras que la otra puerta cerrada pasa a tener probabilidad $2/3$. La entropía de esta nueva distribución es: $H_{\text{final}} = -[(1/3) \times \log_2(1/3) + (2/3) \times \log_2(2/3)] \approx 0,918 \text{ bits}$

La información que efectivamente "inyectó" el presentador al sistema es la reducción de incertidumbre lograda: $\Delta I = H_{\text{inicial}} - H_{\text{final}} \approx 1,585 - 0,918 = 0,667 \text{ bits}$

PRÁCTICO 2: CANAL DE INFORMACIÓN

1. Canal de Clasificación y Probabilidades a Posteriori

Un sistema de ruteo automático de tickets de soporte procesa tres tipos de intenciones de entrada (a_1, a_2, a_3). El algoritmo las procesa y emite tres posibles etiquetas de salida para derivar el ticket (b_1, b_2, b_3). Debido a ambigüedades en el texto, el algoritmo comete errores de clasificación, comportándose como un canal ruidoso definido por la siguiente matriz de transición $P(b_i|a_i)$:

	b1	b2	b3
a1	0,7	0,2	0,1
a2	0,3	0,4	0,3
a3	0,5	0,3	0,2

Sabiendo que el tráfico real de la plataforma presenta la siguiente distribución: $P(a_1)=0,4$, $P(a_2)=0,3$, $P(a_3)=0,3$.

- a) Calcule las probabilidades absolutas de salida $P(b_i)$. ¿Qué porcentaje total de tickets recibe cada etiqueta? b) Calcule la matriz de probabilidades condicionales hacia atrás $P(a_i|b_i)$.
c) Si un operador observa que el sistema etiquetó un ticket como b2, ¿cuál era la verdadera intención de entrada más probable para ese ticket específico?

Resolución

a) Probabilidades absolutas de salida

Usando el Teorema de la Probabilidad Total: $P(b_i) = \sum P(a_i) \times P(b_i|a_i)$

$$P(b_1) = 0,4 \times 0,7 + 0,3 \times 0,3 + 0,3 \times 0,5 = 0,28 + 0,09 + 0,15 = \mathbf{0,52}$$

$$P(b_2) = 0,4 \times 0,2 + 0,3 \times 0,4 + 0,3 \times 0,3 = 0,08 + 0,12 + 0,09 = \mathbf{0,29}$$

$$P(b_3) = 0,4 \times 0,1 + 0,3 \times 0,3 + 0,3 \times 0,2 = 0,04 + 0,09 + 0,06 = \mathbf{0,19}$$

$$\text{Verificación: } 0,52 + 0,29 + 0,19 = 1,00$$

Porcentajes de tickets por etiqueta: $b_1 = 52\%$, $b_2 = 29\%$, $b_3 = 19\%$.

b) Probabilidades hacia atrás $P(a_i|b_i)$

Usando la regla de Bayes:

$$P(a_i|b_j) = \frac{P(a_i \cap b_j)}{P(b_j)} = \frac{P(a_i) \cdot P(b_j|a_i)}{P(b_j)}$$

Dado b1:

- $P(a_1|b_1) = 0,28/0,52 \approx 0,5385$
- $P(a_2|b_1) = 0,09/0,52 \approx 0,1731$
- $P(a_3|b_1) = 0,15/0,52 \approx 0,2885$

Dado b2:

- $P(a_1|b_2) = 0,08/0,29 \approx 0,2759$
- $P(a_2|b_2) = 0,12/0,29 \approx 0,4138$
- $P(a_3|b_2) = 0,09/0,29 \approx 0,3103$

Dado b3:

- $P(a_1|b_3) = 0,04/0,19 \approx 0,2105$
- $P(a_2|b_3) = 0,09/0,19 \approx 0,4737$
- $P(a_3|b_3) = 0,06/0,19 \approx 0,3158$

c) Intención más probable dado b2

Observando el grupo correspondiente a b2:

$P(a_1|b_2) \approx 27,6\%$,

$P(a_2|b_2) \approx 41,4\%$,

$P(a_3|b_2) \approx 31,0\%$.

La probabilidad más alta corresponde a a2. Por lo tanto, si un operador observa un ticket etiquetado como b2, la **intención de entrada más probable es a2** (con un 41,4% de probabilidad a posteriori), aun cuando esa no es una certeza absoluta debido al ruido del canal.

2. Canal Binario Asimétrico en Filtros Anti-Spam

Un modelo clasificador de Machine Learning actúa como un filtro anti-spam, comportándose analíticamente como un Canal Binario Simétrico (BSC). La entrada X representa la naturaleza real del correo (X=0 para "Legítimo", X=1 para "Spam") y la salida Y es la decisión del filtro (Y=0 para "Bandeja de Entrada", Y=1 para "Carpeta Spam"). Estadísticamente, la probabilidad de error del canal simétrico es $p=0,05$.

- Construya la matriz completa de transición del canal $P(Y|X)$ y calcule la matriz de probabilidades conjuntas $P(X,Y)$ asumiendo una probabilidad *a priori* equiprobable para la fuente.
- Calcule la entropía de la fuente $H(X)$ y el ruido del canal (Equivocación) $H(Y|X)$.
- Obtenga la Información Mutua $I(X;Y)$ de este sistema en producción.
- Calcule la Capacidad del Canal C de ese canal.

Resolución

a) Matriz de transición y probabilidades conjuntas

Para un BSC con probabilidad de error $p=0,05$, la matriz de transición es:

P(Y X)	Y=0	Y=1
X=0	1-p = 0,95	p = 0,05
X=1	p = 0,05	1-p = 0,95

Con fuente equiprobable, $P(X=0)=P(X=1)=0,5$. La probabilidad conjunta es $P(x,y) = P(x) \times P(y|x)$:

	Y=0	Y=1
X=0	$0,5 \times 0,95 = 0,475$	$0,5 \times 0,05 = 0,025$
X=1	$0,5 \times 0,05 = 0,025$	$0,5 \times 0,95 = 0,475$

b) Entropía de la fuente y equivocación

$$H(A) = \sum_{i=1}^n p_i * I_i = - \sum_{i=1}^n p_i * \log_2(p_i)$$

Entropía de la fuente (binaria, equiprobable): $H(X) = -[0,5 \times \log_2(0,5) + 0,5 \times \log_2(0,5)] = \mathbf{1 \text{ bit/símbolo}}$

La equivocación $H(Y|X)$ para un BSC coincide con la función entropía $H(p)$ evaluada en la probabilidad de error $p=0,05$:

$$H(Y|X) = H(p) = -[p \times \log_2(p) + (1-p) \times \log_2(1-p)]$$

$$= -[0,05 \times \log_2(0,05) + 0,95 \times \log_2(0,95)]$$

$$\approx 0,2161 + 0,0703$$

$$\approx \mathbf{0,2864 \text{ bits}}$$

c) Información Mutua

$$I(X;Y) = H(Y) - H(Y|X)$$

Como la fuente es equiprobable y el canal es simétrico, la salida también resulta equiprobable ($P(Y=0)=P(Y=1)=0,5$), por lo que: $H(Y) = 1 \text{ bit}$

$$I(X;Y) = 1 - 0,2864 \approx \mathbf{0,7136 \text{ bits/símbolo}}$$

d) Capacidad del canal

Para un BSC, la capacidad se alcanza precisamente cuando la entrada es equiprobable (que es justo la situación de este ejercicio): $C_{\text{BSC}} = 1 - H(p) = 1 - 0,2864 \approx \mathbf{0,7136 \text{ bits/símbolo}}$

En este caso $I(X;Y) = C$, ya que la distribución de entrada dada ($P(X=0)=P(X=1)=0,5$) es exactamente la que maximiza la información mutua en un BSC. Es decir, el filtro anti-spam está operando en las condiciones óptimas para aprovechar al máximo la capacidad del canal.

3. Interfaz Determinista sin Ruido

Considere una conexión determinista entre dos microservicios. Existen tres mensajes posibles de entrada (a_1, a_2, a_3) que se mapean de forma exclusiva y biunívoca a tres mensajes de salida (b_1, b_2, b_3).

a) Escriba la matriz de transición de este canal $P(b_i|a_i)$.

b) Proponga teóricamente una distribución de probabilidades para la fuente de entrada que maximice la entropía.

c) Demuestre analíticamente que, en un canal determinista, el ruido es nulo ($H(B|A)=0$) y la Información Mutua $I(A;B)$ es siempre igual a la entropía de la fuente $H(A)$.

Resolución

a) Matriz de transición

Al ser un mapeo exclusivo y biunívoco (cada entrada se corresponde con una única salida, sin ambigüedad ni ruido), la matriz de transición es la matriz identidad:

	b1	b2	b3
a1	1	0	0
a2	0	1	0
a3	0	0	1

b) Distribución que maximiza la entropía

Como cada fila de la matriz es una permutación de $\{1,0,0\}$, este canal es un caso particular de **canal uniforme**. La teoría establece que la capacidad de un canal uniforme (y, en consecuencia, la máxima entropía de entrada aprovechable) se alcanza cuando la distribución de entrada es **equiprobable**: $P(a_1) = P(a_2) = P(a_3) = 1/3$

Con esta distribución: $H_{\max}(A) = \log_2(3) \approx 1,585 \text{ bits/símbolo}$

c) Demostración: $H(B|A)=0$ y $I(A;B)=H(A)$

Ruido nulo - $H(B|A)=0$:

Por definición: $H(B|A) = \sum_i \sum_j P(a_i, b_j) \times I(b_j|a_i)$

Para cada símbolo de entrada a_i , la matriz tiene un único elemento no nulo: $P(b_j|a_i)=1$ para el j correspondiente, y $P(b_j|a_i)=0$ para el resto. Entonces:

- Cuando $P(b_j|a_i)=1$: $I(b_j|a_i) = \log_2(1/1) = 0$
- Cuando $P(b_j|a_i)=0$: el término $P(a_i, b_j)=0$ y por convención $0 \times \log_2(0) \rightarrow 0$

Por lo tanto, **todos los términos de la sumatoria son nulos**, y en consecuencia: **$H(B|A) = 0$** (queda demostrado)

Esto confirma que un canal determinista no introduce ninguna incertidumbre adicional (ruido): conocer la entrada elimina por completo la incertidumbre sobre la salida.

Información Mutua igual a $H(A)$:

Partiendo de la relación fundamental de la Teoría de la Información: $I(A;B) = H(B) - H(B|A)$

Como acabamos de demostrar que $H(B|A)=0$: $I(A;B) = H(B)$

Además, dado que el mapeo es biunívoco, conocer B determina a A con total certeza, por lo que también se cumple $H(A|B)=0$, y por la relación equivalente: $I(A;B) = H(A) - H(A|B) = H(A) - 0 = H(A)$

Combinando ambas expresiones: **$I(A;B) = H(A) = H(B)$** (queda demostrado)

Esto tiene sentido conceptualmente: en un canal sin ruido y biunívoco, **toda** la información generada por la fuente atraviesa el canal sin ninguna pérdida, por lo que la información mutua (lo que realmente "llega" al receptor) coincide exactamente con la entropía total de la fuente.

4. Codificación Básica e Información Transmitida

Dada una fuente de información que emite los símbolos (a,b,c) con probabilidades $P(a)=1/4$, $P(b)=1/8$, $P(c)=5/8$, y que atraviesa el siguiente canal de comunicación:

	a'	b'	c'
a	1/4	2/4	1/4
b	1/5	3/5	1/5
c	1/3	1/3	1/3

a) Construya un árbol de codificación binaria válido (código prefijo) para la fuente y asigne el código correspondiente a cada símbolo de entrada (a,b,c).

b) Analice la matriz de transición provista. ¿Se trata de un canal uniforme? Justifique brevemente su respuesta observando las filas y columnas.

c) Calcule la entropía de la fuente $H(A)$ y la Información Mutua $I(A;B)$ para determinar cuánta información realmente logra atravesar el canal sin alterarse por el ruido.

Resolución


a) Construcción del código de Huffman (código prefijo)

Ordenamos los símbolos de mayor a menor probabilidad: $c(0,625) > a(0,25) > b(0,125)$.

Agrupamiento (de abajo hacia arriba):

1. Se combinan los 2 símbolos menos probables: $a(0,25)$ y $b(0,125) \rightarrow$ nodo $[a+b]$ con probabilidad 0,375.
2. Se combina el nodo restante $a+b$ con $c(0,625) \rightarrow$ raíz, probabilidad 1,0.

Asignación (de arriba hacia abajo, 0=izquierda, 1=derecha):



Código resultante:

Símbolo	P	Código
c	0,625	0
a	0,25	10
b	0,125	11

Se verifica la desigualdad de Kraft: $2^{-1} + 2^{-2} + 2^{-2} = 0,5 + 0,25 + 0,25 = 1$, por lo que el código es **instantáneo (prefijo) y compacto** (no queda espacio libre en el árbol).

Longitud promedio del código: $L_{\text{prom}} = \sum p_i \times l_i = 0,625(1) + 0,25(2) + 0,125(2) = 0,625 + 0,5 + 0,25 = 1,375$ **bits/símbolo**

b) ¿Es un canal uniforme?

Un canal es uniforme cuando **todas las filas de la matriz de transición son permutaciones entre sí** (es decir, contienen el mismo conjunto de valores, solo reordenados).

Observando las filas:

- Fila a: {0,25; 0,5; 0,25}
- Fila b: {0,2; 0,6; 0,2}
- Fila c: {0,333; 0,333; 0,333}

Estos tres conjuntos de valores **no son permutaciones unos de otros** (cada fila tiene un conjunto de valores numéricos distinto). Por lo tanto, **este canal no es uniforme**. Esto significa que el ruido no afecta de la misma manera a cada símbolo de entrada: por ejemplo, el símbolo c tiene la misma probabilidad de "confundirse" hacia cualquier salida (1/3 cada una), mientras que a y b tienden mucho más fuertemente a confundirse con b'.

c) Entropía de la fuente e Información Mutua

Entropía de la fuente:

$$H(A) = -[(1/4) \times \log_2(1/4) + (1/8) \times \log_2(1/8) + (5/8) \times \log_2(5/8)]$$

$$H(A) = 0,25(2) + 0,125(3) + 0,625(0,6781) \approx 0,5 + 0,375 + 0,4238 \approx 1,2988 \text{ bits/símbolo}$$

Probabilidades de salida (Teorema de la Probabilidad Total):

$$P(a') = (1/4)(1/4) + (1/8)(1/5) + (5/8)(1/3) = 71/240 \approx 0,2958$$

$$P(b') = (1/4)(2/4) + (1/8)(3/5) + (5/8)(1/3) = 49/120 \approx 0,4083$$

$$P(c') = (1/4)(1/4) + (1/8)(1/5) + (5/8)(1/3) = 71/240 \approx 0,2958$$

Entropía de la salida: $H(B) \approx 1,5673$ bits

Equivocación (ruido promedio del canal): se calcula como el promedio ponderado de la entropía de cada fila de la matriz de transición:

$$H(B|A) = \sum_i P(a_i) \times H(B|a_i) \approx 0,25(1,5) + 0,125(1,371) + 0,625(1,585) \approx 1,5370 \text{ bits}$$

Información Mutua: $I(A;B) = H(B) - H(B|A) \approx 1,5673 - 1,5370 \approx 0,0303$ bits/símbolo

Interpretación: de los $H(A) \approx 1,30$ bits/símbolo que genera la fuente, solamente **$\approx 0,03$ bits** logran atravesar el canal de manera confiable. Esto indica que se trata de un **canal extremadamente ruidoso** para esta fuente: casi toda la información original ($H(A|B) \approx 1,27$ bits) se pierde en la transmisión, y lo que recibe el destinatario aporta muy poca certeza real sobre cuál fue el símbolo efectivamente enviado.